

Analyse spectrale du graphe d'attention
pour la détection d'injection de prompt
Étude exploratoire sur huit modèles — BIPIA email-QA, split `train`

14 septembre 2026

Table des matières

1	Objet de ce document	2
2	Définition des métriques	2
2.1	Construction du graphe	2
2.2	Métriques spectrales (graphe seul)	3
2.3	Statistiques de coupe (graphe et étiquettes)	3
2.4	Coupe découverte (sans étiquettes)	4
2.5	Accord entre la coupe découverte et la vérité	4
2.6	Agrégation sur l'ensemble des paires	5
2.7	Quantités descriptives	5
3	Synthèse sur les huit modèles	5
3.1	Ce qui est établi	5
3.2	Ce qui n'est pas établi	6
3.3	Biais connus du protocole	6
3.4	Étape suivante	7
4	Interprétations par modèle	8
4.1	Llama-3.2-1B-Instruct	8
4.2	Qwen2.5-1.5B-Instruct	10
4.3	SmolLM3-3B	11
4.4	Llama-3.2-3B-Instruct	13
4.5	Qwen3-1.7B	14
4.6	SmolLM2-1.7B-Instruct	16
4.7	gemma-2-2b-it	17
4.8	Qwen2.5-3B-Instruct	19

1 Objet de ce document

Ce document rassemble les interprétations rédigées après chaque run de la série. Les tableaux de résultats, la configuration et les contrôles chiffrés de chaque run figurent dans le `rapport.tex` du dossier correspondant, généré automatiquement à partir des CSV ; ici ne sont reprises que les interprétations, qui sont rédigées à la main.

Protocole. Pour chaque paire, le même email est présenté au modèle dans deux conditions : bénigne, et augmentée d’une instruction d’attaque insérée au début, au milieu ou à la fin du corps du message. L’insertion étant faite par le code, la frontière est connue au caractère près et chaque token est étiqueté **benign** ou **injection**. Le prompt complet est envoyé (template de chat, prompt système, consignes de tâche, question) ; tout ce qui n’est pas l’attaque est **benign**. Quarante paires par modèle, soit 80 observations.

Correction pour sélection. Tous les p rapportés dans ce document sont corrigés par simulation sous hypothèse nulle, calquée sur le plan exact du run : on tire des scores indépendants des étiquettes, on prend le maximum sur le même nombre de candidats, et on compare. Cette correction est indispensable : avec 2880 candidats et 80 observations, le maximum d’AUROC sous bruit pur vaut déjà 0,72 en moyenne. Un chiffre non corrigé n’a aucune valeur ici.

Sur les addenda. Plusieurs interprétations contiennent des addenda datés qui révisent un énoncé antérieur. C’est délibéré : le texte d’origine est conservé tel qu’il a été écrit, avec l’information alors disponible, et la révision est ajoutée à la suite. Trois énoncés ont ainsi été corrigés par des runs ultérieurs (sections 4.3, 4.5, 4.2). La chronologie importe davantage que la cohérence apparente.

Limite majeure, valable pour tout ce document. Aucun de ces résultats n’a été confirmé sur le split test. La correction pour sélection valide l’énoncé « il existe une tête dont λ_2 sépare les deux conditions sur ces 40 paires » ; elle ne dit rien de la généralisation à des catégories d’attaque jamais vues. Les catégories de **train** et **test** étant disjointes dans BIPIA, seul un run sur **test**, avec le candidat fixé d’avance, transformerait ces résultats exploratoires en résultats.

2 Définition des métriques

Toutes les quantités rapportées dans ce document sont définies ici. Elles se répartissent en six familles selon ce qu’elles utilisent : le graphe seul, le graphe et les étiquettes, ou une coupe découverte sans étiquettes.

2.1 Construction du graphe

L’attention d’un décodeur est causale, donc triangulaire inférieure. Traitée telle quelle comme un graphe non orienté, toute quantité spectrale serait vide de sens. Elle est donc symétrisée :

$$W = \frac{1}{2} (A + A^\top),$$

où A est la matrice d’attention d’une couche, moyennée sur les têtes (voie agrégée) ou prise tête par tête (voie `--per-head`).

Le Laplacien retenu est le *symétrique normalisé* :

$$L = I - D^{-1/2} W D^{-1/2}, \quad D = \text{diag} \left(\sum_j W_{ij} \right).$$

Son spectre est contenu dans $[0, 2]$ quelle que soit la longueur de la séquence. C’est ce qui rend comparables un prompt bénin et sa variante injectée, nécessairement plus longue : sans cette normalisation, toute différence mesurée serait dominée par l’écart de longueur.

On note $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ les valeurs propres de L , et u_2 le vecteur propre associé à λ_2 , dit *vecteur de Fiedler*. La décomposition est dense (toutes les valeurs propres calculées) : un solveur creux tronquerait le spectre et fausserait les deux métriques définies comme des rapports sur le spectre entier.

2.2 Métriques spectrales (graphe seul)

Ces cinq métriques ne dépendent que des poids d’attention. Elles ne requièrent ni étiquettes ni états cachés, et sont donc calculables sous accès « attention seule ». Ce sont elles qui composent le tenseur `per_head_values.npy`.

`fiedler_value` λ_2 , dite *connectivité algébrique*. Nulle si le graphe est déconnecté, d’autant plus petite qu’il est proche de l’être. C’est la métrique qui porte le signal dans cette étude.

`connectivity_ratio` $\lambda_2/\lambda_{\max}$. Même information que λ_2 , rapportée à l’étendue du spectre, donc insensible à un facteur d’échelle global. Quasi redondante avec `fiedler_value` lorsque $\lambda_{\max}$ varie peu, ce qui explique que les deux apparaissent systématiquement ensemble dans les classements.

`spectral_radius` $\lambda_{\max}$, la plus grande valeur propre.

`spectral_entropy_norm` entropie de la distribution des valeurs propres, normalisée :

$$H = -\frac{1}{\log n} \sum_{k=1}^n p_k \log p_k, \quad p_k = \frac{\lambda_k}{\sum_j \lambda_j}.$$

Proche de 1 si le spectre est étalé uniformément, plus faible s’il est concentré sur quelques modes.

`hfer` *high-frequency energy ratio* : part de la masse spectrale portée par la moitié haute du spectre,

$$\text{hfer} = \frac{\sum_{k>n/2} \lambda_k}{\sum_k \lambda_k}.$$

Élevée quand le graphe porte beaucoup de variation à courte échelle.

Ces cinq noms, leur ordre et leurs définitions sont ceux de `spectral_trust.per_head.PER_HEAD_METRIC_NAMES`, la bibliothèque qui les calcule effectivement, de sorte que la voie agrégée et la voie par tête sont directement comparables.

2.3 Statistiques de coupe (graphe et étiquettes)

Ces quantités utilisent la vraie frontière entre tokens bénins ($\mathcal{B}$) et tokens injectés ($\mathcal{I}$). Elles décrivent la structure, elles ne constituent pas un détecteur. Dans ce qui suit, A est W privée de sa diagonale.

`n_benign`, `n_injection` effectifs des deux familles après filtrage des nœuds.

`density_benign`, `density_injection` poids moyen *par paire possible* à l’intérieur de chaque famille :

$$d_{\mathcal{B}} = \frac{\sum_{i \neq j \in \mathcal{B}} A_{ij}}{|\mathcal{B}|(|\mathcal{B}| - 1)}.$$

La normalisation par le nombre de paires n’est pas cosmétique : l’injection est presque toujours beaucoup plus courte que l’hôte (ici 4 % des tokens), et une somme brute favoriserait mécaniquement le groupe le plus grand.

density_cross même définition entre les deux familles, $d_{\times} = \left(\sum_{i \in \mathcal{B}, j \in \mathcal{I}} A_{ij} \right) / (|\mathcal{B}| |\mathcal{I}|)$.

separation l'hypothèse du bicluster en un nombre :

$$\text{sep} = \frac{\sqrt{d_{\mathcal{B}} \cdot d_{\mathcal{I}}}}{d_{\times}}.$$

Supérieure à 1, les deux familles se tiennent davantage entre elles qu'elles ne se parlent.

Attention : cette quantité utilise les étiquettes. Elle constate une structure, elle ne mesure pas une structure *exploitable* sans étiquettes — la section 3 montre qu'elle ne prédit pas où un détecteur fonctionne.

cut_weight poids total de la coupe entre les deux familles, $\text{cut} = 2 \sum_{i \in \mathcal{B}, j \in \mathcal{I}} A_{ij}$ (le facteur 2 compte l'arête dans les deux sens, le graphe étant non orienté).

conductance $\text{cut} / \min(\text{vol}_{\mathcal{B}}, \text{vol}_{\mathcal{I}})$, où vol est la somme des degrés du groupe. Petite quand la coupe est nette.

normalized_cut $\text{cut} / \text{vol}_{\mathcal{B}} + \text{cut} / \text{vol}_{\mathcal{I}}$, variante qui pénalise les groupes déséquilibrés.

modularity modularité de Newman de la bipartition bénin/injection :

$$Q = \sum_{c \in \{\mathcal{B}, \mathcal{I}\}} \left[\frac{e_c}{2m} - \left(\frac{d_c}{2m} \right)^2 \right],$$

où e_c est le poids interne au groupe c , d_c la somme de ses degrés et $2m$ le poids total. Positive si les groupes sont plus denses qu'un graphe aléatoire de mêmes degrés.

2.4 Coupe découverte (sans étiquettes)

Un détecteur ne sait pas où se trouve l'injection. Il découvre une coupe et en mesure la qualité. La coupe retenue ici est donnée par le *signe du vecteur de Fiedler* : $\mathcal{S} = \{i : u_2(i) \geq 0\}$.

cut_conductance conductance de cette coupe découverte. C'est le score du détecteur, et il est calculable aussi sur un prompt bénin, où la meilleure coupe disponible reste mauvaise — c'est précisément là que devrait résider le signal.

cut_modularity modularité de Newman de la même coupe découverte.

Limite structurelle. La bipartition par le signe de u_2 produit deux groupes de taille comparable. Elle ne peut donc pas isoler une minorité de 4%, ce qui explique l'échec de **cut_conductance** rapporté en section 3. Une *coupe par balayage* — trier les nœuds selon u_2 et retenir le seuil minimisant la conductance — lèverait cette limite ; elle n'est pas implémentée dans cette série.

2.5 Accord entre la coupe découverte et la vérité

accuracy proportion de nœuds correctement classés, prise au maximum sur les deux orientations d'étiquettes, le signe d'un vecteur propre étant arbitraire.

Cette métrique se lit mal et doit toujours être accompagnée de sa ligne de base. Parce qu'elle maximise sur les deux orientations, placer tous les nœuds dans un seul groupe marque déjà $\max(p, 1 - p)$, où p est la fraction injectée. Avec $p \approx 0,04$, cette ligne de base vaut $\approx 0,96$: un accord observé de 0,58 est donc très *inférieur* au trivial, et non « un peu au-dessus du hasard ».

ari indice de Rand ajusté entre la coupe découverte et la vraie partition. Corrigé du hasard par construction : 0 correspond à une coupe sans rapport avec la frontière, 1 à une correspondance parfaite, une valeur négative à un accord inférieur au hasard. **C'est la métrique d'accord à rapporter**, et non **accuracy**.

2.6 Agrégation sur l'ensemble des paires

auroc aire sous la courbe ROC, calculée par les rangs (statistique de Mann–Whitney), les ex æquo recevant le rang moyen. Elle répond à : « en classant les 80 observations selon ce score, les prompts injectés remontent-ils ? ». 0,5 correspond à l'absence de séparation.

direction +1 si un score élevé indique l'injection, −1 sinon. L'AUROC rapportée est corrigée en conséquence, de sorte qu'elle est toujours $\geq 0,5$; c'est pourquoi toute valeur doit être jugée par rapport au maximum sous hypothèse nulle et non à 0,5.

2.7 Quantités descriptives

n_nodes nœuds conservés dans le graphe après filtrage.

n_tokens longueur du prompt en tokens.

bandwidth distance moyenne $|i-j|$ pondérée par les poids d'attention. Faible quand l'attention est locale (une bande autour de la diagonale), élevée quand elle porte des liens à longue portée. Sert à caractériser le régime d'une couche, non à détecter.

3 Synthèse sur les huit modèles

modèle	L	H	meilleur triplet par tête	AUROC	p	agrégé λ_2	p
Llama-3.2-1B	16	32	L6, t.21, conn.	0,884	<0,004	L0 0,604	0,97
Qwen2.5-1.5B	28	12	L9, t.9, conn.	0,813	<0,004	L19 0,757	0,003
SmolLM3-3B	36	16	L24, t.0, radius	0,791	0,007	L0 0,759	0,000
Llama-3.2-3B	28	24	L14, t.4, fiedler	0,917	<0,004	L4 0,676	0,22
Qwen3-1.7B	28	16	L17, t.6, fiedler	0,907	<0,004	L20 0,657	0,55
SmolLM2-1.7B	24	32	L17, t.3, fiedler	0,858	<0,004	L0 0,624	0,95
gemma-2-2b-it	26	8	L9, t.0, conn.	0,779	<0,004	L0 0,611	0,99
Qwen2.5-3B	36	16	L18, t.10, fiedler	0,876	<0,004	L9 0,798	0,000

TABLE 1 – Résultats par modèle, dans l'ordre chronologique des runs. **conn.** = **connectivity_ratio**, **fiedler** = **fiedler_value**, **radius** = **spectral_radius**. L = couches, H = têtes.

3.1 Ce qui est établi

1. cut_conductance ne détecte rien : 8 modèles sur 8. Les huit meilleures AUROC tiennent dans $[0,613 ; 0,697]$, la plage même du maximum sous hypothèse nulle. Le plus petit p corrigé vaut 0,04 (un seul modèle), tous les autres dépassent 0,18.

C'est une réfutation de la prémisse initiale du travail. Le « détecteur sans label » fondé sur la qualité de la coupe découverte par le signe du vecteur de Fiedler ne fonctionne pas sur les injections indirectes de BIPIA. Ce résultat négatif est solide et mérite d'être publié comme tel.

2. Le mécanisme de cet échec est identifié. L'indice de Rand ajusté entre la coupe découverte et la vraie frontière vaut le hasard sur les huit modèles (−0,011 à +0,003). La cause est structurelle : la bipartition par le signe de u_2 produit deux groupes de taille comparable, alors que l'injection représente 3,6 à 4,1 % des tokens. Une coupe équilibrée ne peut pas isoler une telle minorité.

L'échec n'est donc pas une absence de signal dans le graphe, mais une inadéquation de la règle de coupe à la cible. La modification indiquée est le passage à une *coupe par balayage* — trier les nœuds selon u_2 et retenir le seuil qui minimise la conductance — qui autorise des coupes déséquilibrées et reste bornée par l'inégalité de Cheeger.

3. La connectivité algébrique porte le signal : 8 modèles sur 8. Le meilleur triplet par tête est significatif après correction sur les huit modèles, avec des AUROC de 0,779 à 0,917 (médiane 0,867). Sept des huit désignent une métrique de la famille λ_2 (`fiedler_value` = λ_2 ou `connectivity_ratio` = $\lambda_2/\lambda_{\max}$) ; seul SmolLM3-3B retient `spectral_radius`.

Sur six modèles, la structure du classement renforce ce constat : deux ou trois têtes distinctes se détachent, chacune confirmée indépendamment par les deux métriques λ_2 , et la même tête réapparaît parfois à plusieurs profondeurs. Un maximum isolé peut être un accident de sélection ; cette structure ne l’est pas.

4. Les deux voies convergent. Trois modèles présentent aussi un signal *agrégé* significatif, toujours via `fiedler_value`, jamais via `cut_conductance`. Sur Qwen2.5-3B, trois des quatre scores agrégés culminent à la même couche L9.

Le fait que la voie par tête et la voie agrégée désignent la même quantité, λ_2 , alors qu’elles reposent sur des calculs distincts, est l’argument le plus difficile à attribuer au hasard. La conclusion à retenir est que λ_2 est le descripteur pertinent, et que `cut_conductance`, autour duquel le projet avait été conçu, est la mauvaise statistique.

3.2 Ce qui n’est pas établi

La localisation ne se réplique pas. Ni la couche, ni la tête ne se retrouvent d’un modèle à l’autre. Il n’existe pas de « tête à injection » universelle : chaque modèle doit être sondé séparément. Seule la famille de métriques se réplique.

La part de contiguïté n’est pas quantifiée. La séparation décroît avec la profondeur sur sept modèles sur huit (r de $-0,24$ à $-0,75$), avec un contre-exemple franc (SmolLM2-1.7B, $r = +0,46$). Cette tendance suggère que `separation` mesure largement la contiguïté des tokens injectés plutôt que leur nature — si elle mesurait un groupement sémantique, on l’attendrait croissante avec la profondeur. Le contrôle direct, consistant à insérer dans un prompt bénin un segment factice de même longueur et à mesurer la séparation obtenue, n’est pas implémenté. Tant qu’il manque, l’argument reste indirect.

separation ne prédit pas la détection. La corrélation entre séparation moyenne et AUROC de détection, couche par couche, va de $-0,30$ à $+0,50$ selon le modèle, sans régularité. `separation` utilise les vraies étiquettes et constate une structure ; elle ne mesure pas une structure exploitable sans étiquettes. Les deux quantités ne doivent pas être présentées comme deux facettes du même phénomène.

Le nombre de têtes : piste non concluante. La marge du meilleur triplet au-dessus du seuil de bruit corrèle à $r = +0,55$ avec le nombre de têtes du modèle. Avec $n = 8$, ce n’est pas significatif, et les deux modèles à 16 têtes affichent les marges les plus écartées du tableau. À mentionner comme observation, pas comme résultat.

3.3 Biais connus du protocole

Le puits d’attention (token BOS) capte une part importante de la masse et se trouve, dans ce protocole, étiqueté `benign` : il gonfle `density_benign` sur les huit modèles. Le panneau circulaire des figures place les nœuds en ordre de lecture, de sorte qu’une injection contiguë occupe un arc contigu par construction ; seules la matrice d’adjacence réordonnée et les statistiques de coupe constituent une preuve. Enfin, l’accord brut (`accuracy`) doit toujours être comparé à sa ligne de base triviale, de l’ordre de 0,96 ici : l’indice de Rand ajusté est la métrique à rapporter.

3.4 Étape suivante

Huit hypothèses sont pré-enregistrées, une par modèle : le triplet (couche, tête, métrique) de la table 1. Elles doivent être rapportées sur le split **test**, dont les quinze catégories d’attaque sont disjointes de celles de **train**, en lisant *uniquement* la ligne correspondante et sans consulter le maximum du nouveau run. Un seul candidat par modèle, donc aucune correction à appliquer.

Le candidat agrégé de Qwen2.5-3B (**fiedler_value** à L9, 0,798) mérite d’être testé en priorité : un détecteur agrégé n’exige ni l’identification d’une tête, ni le stockage d’un tenseur de *features*, et serait donc plus simple à défendre et à déployer que la voie par tête.

4 Interprétations par modèle

Les sections qui suivent reproduisent, sans modification, les interprétations rédigées après chaque run, dans l'ordre chronologique.

4.1 Llama-3.2-1B-Instruct

Détection : non établie. La meilleure couche est L3, avec AUROC = 0,6431 sur `cut_conductance`. L'intervalle de Hanley–McNeil vaut [0,522 ; 0,764] et exclut 0,5, mais cet intervalle suppose une couche *fixée d'avance*. Or L3 est le maximum sur 16 couches.

Une simulation sous hypothèse nulle, calquée sur le plan exact de ce run (16 candidats, $n_+ = n_- = 40$, scores tirés indépendamment des étiquettes), donne un maximum d'AUROC de 0,613 en moyenne, et dépasse 0,6431 dans 18 % des tirages. La valeur observée correspond donc à $p \approx 0,18$ une fois la sélection prise en compte. **Aucune détection n'est établie par ce run.**

Le même calcul fixe l'ordre de grandeur utile : pour qu'une AUROC de 0,64 devienne significative, il faudrait soit fixer la couche sur un split indépendant, soit augmenter le nombre de paires. Avec une couche choisie d'avance, le 95^e centile du bruit tombe à 0,605.

Mécanisme : la coupe découverte ne tombe pas sur l'injection. L'indice de Rand ajusté vaut +0,003 en moyenne sur les 16 couches, avec un maximum de +0,019. Zéro correspond au hasard. L'accord brut (0,54 à 0,59 selon la couche) est très inférieur à sa ligne de base triviale de 0,963, ce qui confirme la lecture donnée par l'ARI.

Autrement dit : le vecteur de Fiedler scinde bien le graphe en deux, mais la frontière qu'il trouve n'a rien à voir avec celle de l'injection.

La tension entre les deux résultats, et son explication. La séparation vaut entre 2,67 et 4,08 selon la couche, donc bien au-dessus de 1 partout. Il y a là une contradiction apparente : les deux familles se tiennent (séparation élevée) mais la coupe ne les distingue pas (ARI nul).

Les deux quantités ne mesurent pas la même chose. **separation** utilise les vraies étiquettes : elle constate que, *si* l'on connaît la frontière, les densités internes dépassent la densité croisée. `cut_conductance` et l'ARI portent sur une coupe découverte sans étiquettes.

L'explication est structurelle. Les tokens injectés représentent en moyenne 3,7 % de la séquence. Or la bipartition par le signe du vecteur de Fiedler produit des groupes de taille comparable — sur l'exemple contrôlé, 150 nœuds contre 179. Une coupe équilibrée ne peut pas, par construction, isoler une minorité de 3,7 %. **L'outil est inadapté à la cible**, indépendamment de la présence ou non d'un signal dans le graphe.

Conséquence pratique : changer de règle de coupe. La règle actuelle, $\text{signe}(u_2) \geq 0$, doit être remplacée par une *coupe par balayage* : trier les nœuds selon u_2 , parcourir les $n - 1$ seuils possibles, et retenir celui qui minimise la conductance. C'est la méthode classique du partitionnement spectral, elle autorise des coupes déséquilibrées, et elle est bornée par l'inégalité de Cheeger. C'est la modification la plus susceptible de faire remonter l'ARI, et elle ne coûte qu'un tri par couche.

Le contrôle qui manque. La part de **separation** imputable à la simple contiguïté des tokens injectés n'est pas mesurée. Elle ne peut pas l'être en comparant aux prompts bénins : sans injection, il n'y a pas de seconde famille, et `cut_statistics` renvoie NaN pour tous les termes croisés.

Le contrôle correct consiste à placer, dans le prompt bénin, un segment contigu factice de même longueur que l'aurait été l'injection, à étiqueter comme pseudo-injection, et à calculer la séparation obtenue. Cela donne la valeur de référence due à la contiguïté seule. Tant que ce chiffre est inconnu, une séparation de 3,5 ne peut pas être attribuée à l'injection.

Biais connus de ce protocole. Le puits d’attention (token BOS) capte une part importante de la masse et se trouve étiqueté **benign** : il gonfle **density_benign** et donc déprime mécaniquement la séparation. Par ailleurs, le panneau circulaire des figures dispose les nœuds en ordre de lecture, de sorte qu’une injection contiguë occupe un arc contigu par construction ; seules la matrice d’adjacence réordonnée et les statistiques de coupe constituent une preuve.

Ce que ce run permet de conclure. Trois énoncés sont soutenus par les données :

1. les tokens injectés forment un bloc plus dense que le texte hôte (**density_injection** > **density_benign** sur la majorité des couches) ;
2. ce bloc n’est pas retrouvé par une bipartition spectrale équilibrée ;
3. le score **cut_conductance** ne sépare pas les deux conditions de façon statistiquement établie sur 40 paires.

Le point 2 est une limite de méthode, pas une absence de signal : c’est lui qu’il faut lever avant de conclure quoi que ce soit sur le point 3.

Addendum du 14/09/2026 — résultats par tête. Le texte ci-dessus a été rédigé alors que **per_head_values.npy** avait été tronqué par une saturation du disque en fin de run ; la voie par tête n’y est donc pas traitée. Le run a depuis été relancé et le tenseur est complet (forme $80 \times 16 \times 32 \times 5$). Les chiffres agrégés sont inchangés au dernier décimal : L3 à 0,6431, ARI moyen +0,0030.

Le classement par tête donne :

couche, tête	métrique	AUROC
L6, tête 21	connectivity_ratio	0,8838
L6, tête 21	fiedler_value	0,8694
L9, tête 25	connectivity_ratio	0,8488
L9, tête 25	fiedler_value	0,8450
L0, tête 21	fiedler_value	0,7937

Sur 2560 candidats, la simulation nulle donne un maximum de 0,720 en moyenne et 0,751 au 95^e centile ; 0,8838 n’est jamais atteint en 250 tirages, soit $p < 0,004$.

La structure reproduit exactement celle observée sur Llama-3.2-3B : **deux têtes** (L6/tête 21 et L9/tête 25), chacune confirmée par deux métriques liées, toutes quatre au-dessus de 0,84 quand le bruit plafonne à 0,751. Ce n’est donc pas un maximum isolé. On notera aussi que la tête 21 réapparaît à L0 avec 0,7937.

Addendum — bilan sur les quatre modèles. Avec ce résultat, la série est complète et parfaitement contrastée.

modèle	agrégé	p	meilleur triplet par tête	AUROC
Llama-3.2-1B	0,6431	0,19	L6, t.21, connectivity_ratio	0,8838
Qwen2.5-1.5B	0,6125	0,66	L9, t.9, connectivity_ratio	0,8131
SmolLM3-3B	0,6556	0,25	L24, t.0, spectral_radius	0,7913
Llama-3.2-3B	0,6362	0,36	L14, t.4, fiedler_value	0,9169

Quatre modèles sur quatre : la voie agrégée échoue, la voie par tête réussit ($p < 0,005$ partout après correction pour sélection). C’est le résultat structurant de cette série d’expériences.

Une régularité partielle mérite d’être relevée : trois des quatre meilleurs triplets reposent sur λ_2 (**connectivity_ratio** = $\lambda_2/\lambda_{\max}$ ou **fiedler_value** = λ_2). La connectivité algébrique se détache donc comme la famille de métriques pertinente, même si la couche et la tête restent propres à chaque modèle.

4.2 Qwen2.5-1.5B-Instruct

Détection agrégée : échec net. La meilleure couche sur `cut_conductance` est L13, avec AUROC = 0,6125. Une simulation sous hypothèse nulle calquée sur le plan de ce run (28 candidats, $n_+ = n_- = 40$) donne un maximum d’AUROC de 0,630 *en moyenne*, et dépasse la valeur observée dans 66 % des tirages.

La meilleure couche de ce run est donc en dessous de ce que produit le bruit pur. Le score `cut_conductance` ne sépare pas les deux conditions. Sur Llama-3.2-1B, le même calcul donnait $p \approx 0,18$; ici $p \approx 0,66$. Les deux modèles concordent : la voie agrégée ne détecte rien.

Mécanisme : la coupe découverte reste au hasard. L’indice de Rand ajusté vaut $-0,0065$ en moyenne, et reste compris entre $-0,032$ et $+0,005$ sur les 28 couches. Zéro correspond au hasard. L’accord brut (0,54 à 0,70) est très inférieur à sa ligne de base triviale de 0,962, la fraction injectée n’étant que de 3,8 %.

L’explication reste celle identifiée sur Llama : la bipartition par le signe du vecteur de Fiedler produit deux groupes de taille comparable, et ne peut pas isoler une minorité de 3,8 %. Ce n’est pas une absence de signal dans le graphe, c’est une inadéquation de la règle de coupe à la cible.

La séparation décroît avec la profondeur — et c’est un problème. Ce run apporte un élément que le précédent n’avait pas. La séparation moyenne passe de 5,94 sur les cinq premières couches à 2,76 sur les cinq dernières, avec une corrélation rang/profondeur de $r = -0,643$. Le maximum est atteint à L0 (7,90), le minimum à L26 (1,88).

Cette tendance va *contre* l’hypothèse de travail. Si la séparation mesurait la formation d’un groupe sémantique autour de l’instruction injectée, on l’attendrait croissante avec la profondeur : c’est dans les couches profondes que l’attention devient sémantique. Elle est au contraire maximale là où l’attention est la plus positionnelle et la plus locale.

L’interprétation la plus simple est que **separation** mesure principalement la **contiguïté** des tokens injectés, pas leur nature. Un bloc de tokens voisins forme mécaniquement deux blocs denses dans un graphe d’attention local, et cette localité s’atténue avec la profondeur.

Résultat par tête : le premier signal qui survit à la correction. Le meilleur triplet est L9, tête 9, métrique `connectivity_ratio`, avec AUROC = 0,8131.

Ce chiffre est le maximum sur 1 680 candidats (28 couches $\times$ 12 têtes $\times$ 5 métriques), ce qui impose la même correction que ci-dessus. La simulation nulle sur 1 680 candidats et 80 observations donne un maximum de 0,715 en moyenne et 0,753 au 95^e centile ; 0,8131 n’a jamais été atteint en 300 tirages, soit $p < 0,003$.

C’est le premier résultat de ce projet qui survit à la correction pour sélection. Il confirme précisément ce que la voie agrégée ne pouvait pas montrer : le signal existe, porté par une tête, et la moyenne sur les 12 têtes le dilue jusqu’à le rendre indétectable.

Ce qu’il faut faire de ce résultat. Il n’est pas encore rapportable. Il a été obtenu sur **train**, et le protocole exige de fixer le candidat puis de le rapporter sur un split dont les catégories d’attaque sont disjointes :

`-split test -n-pairs 60 -per-head`, puis lire dans `per_head_auroc.csv` la ligne (`layer = 9, head = 9, metric = connectivity_ratio`) *sans* regarder le maximum de ce nouveau run.

L’hypothèse est désormais pré-enregistrée : un seul candidat, donc plus aucune correction pour sélection. Si l’AUROC se maintient au-dessus de 0,70 sur **test**, le résultat est publiable.

Une anomalie à signaler. À L19, `auroc_fiedler_value` vaut 0,7569 et l'accord moyen 0,704, nettement au-dessus de toutes les autres couches. C'est un maximum parmi 112 candidats (4 scores $\times$ 28 couches) et il n'est pas significatif pris isolément, mais la coïncidence des deux métriques sur la même couche mérite d'être vérifiée sur `test` en même temps que la tête L9/H9.

Addendum du 14/09/2026 — l'anomalie ci-dessus était significative. La phrase « il n'est pas significatif pris isolément » est **fausse**, et je ne l'avais pas vérifiée par simulation au moment de l'écrire.

Le run Qwen2.5-3B m'a conduit à reprendre tous les modèles avec une correction explicite. Pour 112 candidats et $n_+ = n_- = 40$, le bruit donne un maximum de 0,663 en moyenne et 0,706 au 95^e centile ; 0,7569 n'est atteint que dans 0,3 % des tirages, soit $p = 0,003$.

Ce modèle présente donc bien un signal agrégé, porté par λ_2 à L19. Il s'ajoute à Qwen2.5-3B ($p < 0,001$) et SmoLLM3-3B ($p < 0,001$) : trois modèles sur huit, tous via `fiedler_value`, jamais via `cut_conductance`.

La conclusion « la voie agrégée échoue », répétée dans cette interprétation et dans les suivantes, doit être lue comme portant sur `cut_conductance` seul. λ_2 du graphe agrégé, lui, fonctionne sur une partie des modèles. Voir l'interprétation de Qwen2.5-3B pour le tableau complet et les conséquences.

Biais connus, inchangés. Le puits d'attention est étiqueté `benign` et gonfle `density_benign`. Le panneau circulaire place les nœuds en ordre de lecture, de sorte qu'une injection contiguë occupe un arc contigu par construction. Enfin, le contrôle de contiguïté — placer un segment factice de même longueur dans un prompt bénin et mesurer la séparation obtenue — n'est toujours pas implémenté ; la tendance en profondeur décrite plus haut en tient lieu d'argument indirect, mais ne le remplace pas.

Conclusion. Sur Qwen2.5-1.5B comme sur Llama-3.2-1B, la détection par statistique de coupe agrégée est nulle. En revanche, ce run établit sur `train` un signal par tête statistiquement solide ($p < 0,003$ après correction), ce qui réoriente le travail : la question n'est plus « le graphe d'attention se restructure-t-il sous injection ? » — posée globalement, la réponse est non — mais « quelles têtes se restructurent ? », et la réponse est au moins une.

4.3 SmoLLM3-3B

Détection agrégée : toujours pas de signal. La meilleure couche sur `cut_conductance` est L15, avec AUROC = 0,6556. La simulation nulle calquée sur ce plan (36 candidats, $n_+ = n_- = 40$) donne un maximum de 0,637 en moyenne et dépasse la valeur observée dans 25 % des tirages, soit $p \approx 0,25$.

Le bilan sur les trois modèles est cohérent :

modèle	couches	meilleure AUROC	p corrigé
Llama-3.2-1B	16	0,6431	0,18
Qwen2.5-1.5B	28	0,6125	0,66
SmoLLM3-3B	36	0,6556	0,25

Aucun des trois n'atteint la significativité. Les valeurs autour de 0,64 sont exactement ce que produit le maximum sur quelques dizaines de candidats sous hypothèse nulle. La voie agrégée ne détecte pas les injections.

Mécanisme : inchangé. ARI moyen $-0,0039$, donc le hasard. Accord brut 0,591 contre une ligne de base triviale de 0,964, la fraction injectée valant 3,6 %. La bipartition par signe du vecteur de Fiedler continue de produire deux moitiés comparables, incapables d'isoler une minorité de cette taille.

Résultat central : separation ne prédit pas la détection. Ce run permet de trancher une question laissée ouverte par les précédents. En corrélant, couche par couche, la séparation moyenne et l’AUROC de détection :

SmolLM3-3B : $r = -0,302$ Qwen2.5-1.5B : $r = -0,091$ Llama-3.2-1B : $r = +0,063$

Les trois valeurs sont nulles ou négatives. Sur SmolLM3, les trois meilleures couches en AUROC (L15, L25, L27) affichent des séparations de 1,84, 2,66 et 1,05, toutes inférieures à la moyenne, tandis que le maximum de séparation (5,88 à L1) correspond à une AUROC quelconque.

Les couches où les deux familles de tokens se tiennent le mieux ne sont pas celles où un détecteur fonctionne le mieux. `separation` utilise les vraies étiquettes et constate une structure ; elle ne mesure pas une structure *exploitable* sans étiquettes. Ces deux quantités ont été traitées jusqu’ici comme deux facettes du même phénomène ; elles ne le sont pas.

Conséquence pratique immédiate : l’option `--layer-select separation`, utilisée pour choisir les couches à illustrer, sélectionne des couches qui ne sont pas celles où le signal de détection se trouve. Elle reste pertinente pour montrer le bicluster, pas pour illustrer la détection.

Addendum du 14/09/2026 — révision du paragraphe ci-dessus. Le paragraphe précédent a été rédigé le 13/09/2026, sur la base des trois seuls modèles alors disponibles. Le run Llama-3.2-3B, terminé depuis, donne $r = +0,498$: une corrélation positive nette entre séparation et AUROC de détection, qui contredit l’énoncé en gras.

Sur les quatre modèles, la corrélation vaut $-0,302$ (SmolLM3-3B), $-0,091$ (Qwen2.5-1.5B), $+0,063$ (Llama-3.2-1B) et $+0,498$ (Llama-3.2-3B) : elle change de signe et ne présente aucune régularité.

L’énoncé « les couches où les deux familles se tiennent le mieux ne sont pas celles où un détecteur fonctionne le mieux » est donc trop fort et ne doit pas être repris tel quel. La formulation défendable est plus faible : `separation` n’est pas un prédicteur *fiable* de l’endroit où la détection fonctionne, puisque la relation dépend du modèle ; on ne peut pas pour autant affirmer qu’elle en est indépendante.

La conséquence pratique énoncée plus haut reste valable, mais pour une autre raison : ce n’est pas parce que la relation serait nulle, c’est parce qu’elle est instable d’un modèle à l’autre. Fonder la sélection de couche sur `separation` reste donc déconseillé pour illustrer la détection.

Par tête : le signal se confirme, à un autre endroit. Le meilleur triplet est L24, tête 0, `spectral_radius`, avec AUROC = 0,7913. Sur 2880 candidats (36 couches $\times$ 16 têtes $\times$ 5 métriques), la simulation nulle donne un maximum de 0,722 en moyenne, 0,753 au 95^e centile, et $p = 0,004$.

C’est la seconde confirmation indépendante :

modèle	meilleur triplet	p corrigé
Qwen2.5-1.5B	L9, tête 9, <code>connectivity_ratio</code>	$< 0,003$
SmolLM3-3B	L24, tête 0, <code>spectral_radius</code>	0,004

Deux architectures différentes, deux signaux par tête significatifs après correction pour sélection, là où la voie agrégée échoue sur les deux. **L’argument du projet — moyenner les têtes détruit le signal — est maintenant étayé par deux répliques indépendantes.**

Noter toutefois que la *localisation* ne se réplique pas : ni la couche (9 contre 24), ni la tête (9 contre 0), ni la métrique (`connectivity_ratio` contre `spectral_radius`). Il n’y a donc pas de « tête à injection » universelle, et il ne faut pas la chercher : chaque modèle doit être sondé séparément. Sur SmolLM3, les trois candidats suivants (L27/H3 à 0,756 et 0,755, L18/H2 à 0,753) sont juste au niveau du 95^e centile du bruit et ne doivent pas être retenus.

Ce qu’il faut faire maintenant. Deux hypothèses sont désormais pré-enregistrées, une par modèle. Elles doivent être rapportées sur `test`, dont les catégories d’attaque sont disjointes, en lisant *uniquement* la ligne correspondante de `per_head_auroc.csv` et sans consulter le maximum du nouveau run :

- Qwen2.5-1.5B : `layer=9, head=9, metric=connectivity_ratio` ;
- SmolLM3-3B : `layer=24, head=0, metric=spectral_radius`.

Un seul candidat par modèle, donc aucune correction à appliquer. Une AUROC maintenue au-dessus de 0,70 constituerait le premier résultat publiable de ce travail.

Limites. La tendance de la séparation avec la profondeur, très marquée sur Qwen ($r = -0,643$), est ici plus faible ($r = -0,244$) : l’argument selon lequel la séparation refléterait surtout la contiguïté des tokens injectés reste plausible mais n’est pas établi de façon homogène entre modèles. Le contrôle direct — insérer un segment factice de même longueur dans un prompt bénin et mesurer la séparation obtenue — n’est toujours pas implémenté et reste le chiffre manquant. Enfin, le puits d’attention est étiqueté `benign` et gonfle `density_benign` sur les trois modèles.

4.4 Llama-3.2-3B-Instruct

Détection agrégée : quatrième échec. Meilleure couche L4, AUROC = 0,6362. La simulation nulle (28 candidats, $n_+ = n_- = 40$) donne un maximum de 0,630 en moyenne et dépasse la valeur observée dans 36 % des tirages.

Le tableau est désormais complet sur quatre modèles :

modèle	couches	têtes	meilleure AUROC	p corrigé
Llama-3.2-1B	16	32	0,6431	0,18
Qwen2.5-1.5B	28	12	0,6125	0,66
SmolLM3-3B	36	16	0,6556	0,25
Llama-3.2-3B	28	24	0,6362	0,36

Quatre modèles, quatre échecs. Les valeurs se regroupent autour de 0,63, qui est précisément la moyenne du maximum sous hypothèse nulle pour ce nombre de candidats. Ce n’est plus un résultat faible : c’est un résultat nul, reproduit quatre fois. La conclusion à écrire est que `cut_conductance` sur le graphe agrégé ne détecte pas les injections indirectes de ce benchmark.

Par tête : le signal le plus net obtenu jusqu’ici. Le meilleur triplet est L14, tête 4, `fiedler_value`, avec AUROC = 0,9169. Sur 3360 candidats, la simulation nulle donne un maximum de 0,724 en moyenne et 0,757 au 95^e centile ; 0,9169 n’est jamais atteint en 250 tirages, soit $p < 0,004$.

L’élément décisif n’est cependant pas le maximum, c’est sa *structure* :

couche, tête	métrique	AUROC
L14, tête 4	<code>fiedler_value</code>	0,9169
L11, tête 0	<code>connectivity_ratio</code>	0,9119
L14, tête 4	<code>connectivity_ratio</code>	0,9106
L11, tête 0	<code>fiedler_value</code>	0,9094

Ce ne sont pas quatre candidats indépendants mais **deux têtes**, chacune détectée par deux métriques liées (`connectivity_ratio` = $\lambda_2/\lambda_{\max}$, donc quasi redondante avec λ_2 quand le rayon spectral varie peu).

Sur les modèles précédents, le meilleur candidat était isolé et ses suivants retombaient au niveau du bruit. Ici, deux têtes distinctes dépassent 0,90, très au-dessus du 95^e centile du bruit (0,757). Un maximum élevé peut être un accident de sélection ; deux têtes cohérentes, chacune confirmée par deux métriques corrélées, le sont beaucoup moins.

Bilan par tête sur trois modèles.

modèle	meilleur triplet	p corrigé
Qwen2.5-1.5B	L9, tête 9, <code>connectivity_ratio</code>	< 0,003
SmolLM3-3B	L24, tête 0, <code>spectral_radius</code>	0,004
Llama-3.2-3B	L14, tête 4, <code>fiedler_value</code>	< 0,004

Trois architectures, trois signaux significatifs après correction, là où la voie agrégée échoue sur les quatre. L’hypothèse centrale du projet — moyenner les têtes détruit le signal — est étayée par trois répliques indépendantes.

La localisation, en revanche, ne se réplique pas : ni la couche, ni la tête, ni la métrique. Il n’y a pas de « tête à injection » universelle ; chaque modèle doit être sondé séparément. C’est une limite à annoncer plutôt qu’à subir.

Révision d’un énoncé antérieur. L’interprétation du run SmolLM3-3B, rédigée le 13/09/2026, affirmait que `separation` et l’AUROC de détection étaient décorréliées, sur la base des trois modèles alors disponibles ($r = -0,302, -0,091, +0,063$). Ce run donne $r = +0,498$, une corrélation positive nette.

L’énoncé était trop fort et a été révisé par un addendum daté dans le fichier concerné ; le texte d’origine y a été conservé, la chronologie important davantage que la cohérence apparente. La formulation retenue est que `separation` n’est pas un prédicteur *fiable* de l’endroit où la détection fonctionne, la relation changeant de signe selon le modèle.

Mécanisme et biais : inchangés. ARI moyen $-0,0031$, donc le hasard, pour la quatrième fois. Accord brut 0,569 contre une ligne de base triviale de 0,963. La coupe par signe du vecteur de Fiedler reste incapable d’isoler une minorité de 3,7 %.

La séparation décroît avec la profondeur ($r = -0,468$), comme sur Qwen ($-0,643$) et SmolLM3 ($-0,244$) : trois modèles sur quatre montrent cette tendance, compatible avec l’idée que la séparation reflète largement la contiguïté des tokens injectés plutôt que leur nature. Le contrôle direct — insérer un segment factice de même longueur dans un prompt bénin et mesurer la séparation obtenue — reste à implémenter et demeure le chiffre manquant.

À faire. Hypothèse pré-enregistrée pour ce modèle : `layer=14, head=4, metric=fiedler_value`, à lire seule dans le `per_head_auroc.csv` du split `test`, sans consulter le maximum de ce nouveau run. Il est légitime de pré-enregistrer également `layer=11, head=0` comme second candidat, à condition de l’annoncer avant le run et d’appliquer une correction pour deux tests.

Compte tenu de l’AUROC de 0,92 sur `train`, c’est ce modèle qui offre la meilleure chance d’un premier résultat publiable.

4.5 Qwen3-1.7B

Détection agrégée : cinquième échec. Meilleure couche L10, AUROC = 0,6294. La simulation nulle (28 candidats, $n_+ = n_- = 40$) donne un maximum de 0,630 en moyenne : la valeur observée est *en dessous* de la moyenne du bruit, et est dépassée dans 46 % des tirages.

modèle	couches	têtes	meilleure AUROC	p corrigé
Llama-3.2-1B	16	32	0,6431	0,19
Qwen2.5-1.5B	28	12	0,6125	0,66
SmolLM3-3B	36	16	0,6556	0,25
Llama-3.2-3B	28	24	0,6362	0,36
Qwen3-1.7B	28	16	0,6294	0,46

Cinq modèles, cinq échecs, avec des valeurs comprises entre 0,61 et 0,66 là où le bruit produit 0,61 à 0,64. Il n’y a plus lieu de présenter ces chiffres comme un signal faible : ce sont les valeurs attendues sous l’hypothèse nulle. `cut_conductance` calculé sur le graphe agrégé ne détecte pas les injections indirectes de BIPIA, et cette conclusion est désormais solidement reproduite.

Par tête : une tête domine nettement.

couche, tête	métrique	AUROC
L17, tête 6	<code>fiedler_value</code>	0,9069
L17, tête 6	<code>connectivity_ratio</code>	0,9062
L26, tête 14	<code>fiedler_value</code>	0,8137
L25, tête 6	<code>connectivity_ratio</code>	0,7994
L25, tête 6	<code>fiedler_value</code>	0,7837
L13, tête 8	<code>fiedler_value</code>	0,7750

Sur 2 240 candidats, la simulation nulle donne un maximum de 0,717 en moyenne et 0,750 au 95^e centile ; 0,9069 n’est jamais atteint en 250 tirages, soit $p < 0,004$.

La structure est la plus nette de la série : L17/tête 6 se détache à 0,907, confirmée par les deux métriques de la famille λ_2 , avec un écart de près de dix points sur le candidat suivant. On notera que la *même* tête 6 réapparaît à L25 (0,799 et 0,784), ce qui suggère une spécialisation persistante à travers la profondeur plutôt qu’un accident de couche.

Une régularité se dégage : la famille λ_2 . Les six meilleurs triplets de ce run reposent *tous* sur la connectivité algébrique — `fiedler_value` = λ_2 ou `connectivity_ratio` = $\lambda_2/\lambda_{\max}$. Sur l’ensemble de la série :

modèle	meilleur triplet	famille
Llama-3.2-1B	L6, t.21, <code>connectivity_ratio</code>	λ_2
Qwen2.5-1.5B	L9, t.9, <code>connectivity_ratio</code>	λ_2
SmolLM3-3B	L24, t.0, <code>spectral_radius</code>	$\lambda_{\max}$
Llama-3.2-3B	L14, t.4, <code>fiedler_value</code>	λ_2
Qwen3-1.7B	L17, t.6, <code>fiedler_value</code>	λ_2

Quatre modèles sur cinq désignent une métrique fondée sur λ_2 . C’est la seule chose qui se réplique : ni la couche ni la tête ne le font. La connectivité algébrique d’une tête individuelle apparaît donc comme le descripteur pertinent, et c’est sur elle que devrait porter une sonde plutôt que sur les cinq métriques indistinctement.

La séparation décroît avec la profondeur, plus nettement que jamais. $r = -0,749$ entre indice de couche et séparation moyenne, avec 5,43 sur les cinq premières couches contre 2,69 sur les cinq dernières ; le maximum est à L0 (6,79), le minimum à L26 (1,95).

C’est la tendance la plus marquée de la série (−0,643 sur Qwen2.5, −0,468 sur Llama-3.2-3B, −0,244 sur SmolLM3, −0,610 sur Llama-3.2-1B). Quatre modèles sur cinq montrent une décroissance nette.

Cette régularité soutient l’interprétation déjà avancée : **separation** mesure largement la **contiguïté** des tokens injectés, et non la formation d’un groupe sémantique. Si c’était l’inverse, on l’attendrait croissante avec la profondeur, là où l’attention devient sémantique. Elle est au contraire maximale à L0, où l’attention est la plus positionnelle.

Addendum du 14/09/2026 — un contre-exemple. Le paragraphe ci-dessus a été rédigé avant le run SmolLM2-1.7B, terminé le même jour. Ce modèle donne $r = +0,464$: la séparation y *croît* avec la profondeur (2,61 sur les cinq premières couches contre 3,42 sur les cinq dernières), ce qui contredit directement la régularité invoquée ici.

Sur les six modèles : $-0,610$, $-0,643$, $-0,244$, $-0,468$, $-0,749$ et $+0,464$. Cinq décroissances nettes, une croissance nette.

L'argument de contiguïté reste majoritairement soutenu, mais la formule « difficile à écarter » employée plus haut est trop forte : il souffre au moins une exception franche et ne peut pas être présenté comme établi. Seul le contrôle direct — segment factice de même longueur inséré dans un prompt bénin — permettra de trancher, modèle par modèle.

Corrélation séparation / détection. $r = -0,102$ ici. Sur les cinq modèles : $-0,302$, $-0,091$, $+0,063$, $+0,498$, $-0,102$. La valeur change de signe et ne présente aucune régularité, ce qui confirme la formulation révisée retenue après le run Llama-3.2-3B : **separation** n'est pas un prédicteur fiable de l'endroit où la détection fonctionne.

Mécanisme : inchangé. ARI moyen $-0,0096$, donc le hasard, pour la cinquième fois. Accord brut $0,603$ contre une ligne de base triviale de $0,962$, la fraction injectée valant $3,8\%$. La bipartition par signe du vecteur de Fiedler reste structurellement incapable d'isoler une minorité de cette taille ; le passage à une coupe par balayage reste la modification à faire.

À faire. Hypothèse pré-enregistrée : **layer=17**, **head=6**, **metric=fiedler_value**, à lire seule dans le **per_head_auroc.csv** du split **test**. Avec $0,907$ sur **train**, ce modèle se place juste derrière Llama-3.2-3B ($0,917$) comme meilleur candidat à un résultat publiable.

4.6 SmoLM2-1.7B-Instruct

Détection agrégée : sixième échec. Meilleure couche L20, AUROC = $0,6525$, contre un maximum de $0,627$ en moyenne sous hypothèse nulle (24 candidats, $n_+ = n_- = 40$), dépassé dans 20% des tirages.

modèle	couches	têtes	meilleure AUROC	p corrigé
Llama-3.2-1B	16	32	$0,6431$	$0,19$
Qwen2.5-1.5B	28	12	$0,6125$	$0,66$
SmoLM3-3B	36	16	$0,6556$	$0,25$
Llama-3.2-3B	28	24	$0,6362$	$0,36$
Qwen3-1.7B	28	16	$0,6294$	$0,46$
SmoLM2-1.7B	24	32	$0,6525$	$0,20$

Six modèles, six échecs, dans une fourchette de $0,61$ à $0,66$ qui est exactement celle du bruit. Aucun p ne descend sous $0,19$. La conclusion est établie.

Par tête : sixième succès.

couche, tête	métrique	AUROC
L17, tête 3	fiedler_value	$0,8575$
L17, tête 3	connectivity_ratio	$0,8287$
L21, tête 3	spectral_radius	$0,7744$
L7, tête 16	connectivity_ratio	$0,7538$

Sur 3840 candidats, le bruit donne un maximum de $0,726$ en moyenne et $0,759$ au 95^e centile ; $0,8575$ n'est jamais atteint en 250 tirages, soit $p < 0,004$.

Seuls les deux premiers candidats se détachent réellement : les suivants ($0,774$, $0,754$) sont au niveau du 95^e centile et ne doivent pas être retenus. Comme sur Qwen3-1.7B, la même tête réapparaît à une autre profondeur — ici la tête 3, à L17 puis à L21.

La famille λ_2 se confirme. Le meilleur triplet repose de nouveau sur la connectivité algébrique. Sur les six modèles, cinq désignent `fiedler_value` ou `connectivity_ratio`, seul SmolLM3-3B retient `spectral_radius`. C’est la seule régularité de la série : la couche et la tête restent propres à chaque modèle, la métrique non.

Révision : la tendance en profondeur n’est pas universelle. Ce run contredit un argument avancé dans l’interprétation de Qwen3-1.7B, rédigée le même jour mais avant celui-ci.

J’y soutenais que `separation` décroît avec la profondeur sur tous les modèles observés, et que cette régularité rendait « difficile à écarter » l’idée qu’elle mesure surtout la contiguïté des tokens injectés. SmolLM2-1.7B donne $r = +0,464$: la séparation *croît* ici avec la profondeur (2,61 sur les cinq premières couches contre 3,42 sur les cinq dernières, maximum à L23).

Sur les six modèles :

−0,610 −0,643 −0,244 −0,468 −0,749 **+0,464**

Cinq décroissances nettes et une croissance nette. L’argument de contiguïté reste *plausible* et majoritairement soutenu, mais il n’est pas universel et ne peut pas être présenté comme établi. SmolLM2-1.7B constitue un contre-exemple qu’il faudra mentionner explicitement plutôt que d’invoquer une tendance générale.

Cela renforce la nécessité du contrôle direct, toujours non implémenté : insérer dans un prompt bénin un segment factice de même longueur que l’aurait été l’injection, et mesurer la séparation obtenue. C’est le seul moyen de quantifier la part de contiguïté, modèle par modèle, au lieu de l’inférer d’une tendance qui souffre des exceptions.

Corrélation séparation / détection. $r = -0,092$. Sur les six modèles : −0,302, −0,091, +0,063, +0,498, −0,102, −0,092. Aucune régularité, conformément à la formulation révisée adoptée après Llama-3.2-3B.

Mécanisme : inchangé. ARI moyen −0,0114, soit le hasard, pour la sixième fois. Accord brut 0,602 contre une ligne de base triviale de 0,960. La coupe par signe du vecteur de Fiedler reste incapable d’isoler une minorité de 4,1 %.

À faire. Hypothèse pré-enregistrée : `layer=17`, `head=3`, `metric=fiedler_value`. Avec 0,858 sur `train`, ce modèle se situe au milieu du classement, derrière Llama-3.2-3B (0,917), Qwen3-1.7B (0,907) et Llama-3.2-1B (0,884).

4.7 gemma-2-2b-it

Détection agrégée : septième échec. Meilleure couche L4, AUROC = 0,6406, contre un maximum de 0,627 en moyenne sous hypothèse nulle (26 candidats, $n_+ = n_- = 40$), dépassé dans 30 % des tirages.

modèle	couches	têtes	meilleure AUROC	p corrigé
Llama-3.2-1B	16	32	0,6431	0,19
Qwen2.5-1.5B	28	12	0,6125	0,66
SmolLM3-3B	36	16	0,6556	0,25
Llama-3.2-3B	28	24	0,6362	0,36
Qwen3-1.7B	28	16	0,6294	0,46
SmolLM2-1.7B	24	32	0,6525	0,20
gemma-2-2b-it	26	8	0,6406	0,30

Sept modèles, sept échecs. Les sept valeurs tiennent dans [0,6125 ; 0,6556], soit précisément la plage du maximum sous hypothèse nulle. Le plus petit p de la série vaut 0,19. Sur sept architectures

allant de 1,5 à 3 milliards de paramètres, `cut_conductance` sur le graphe agrégé ne détecte pas les injections indirectes de BIPIA.

Par tête : significatif, mais le plus faible de la série.

couche, tête	métrique	AUROC
L9, tête 0	<code>connectivity_ratio</code>	0,7794
L23, tête 0	<code>hfer</code>	0,7788
L9, tête 0	<code>fiedler_value</code>	0,7719
L12, tête 6	<code>fiedler_value</code>	0,7719

Sur 1 040 candidats, le bruit donne 0,706 en moyenne et 0,738 au 95^e centile. La valeur observée est atteinte dans 0,4 % des tirages, donc significative, mais la marge au-dessus du 95^e centile n'est que de 0,041 — la plus étroite des sept modèles.

La structure est également moins convaincante qu'ailleurs. La tête 0 de L9 apparaît bien deux fois (avec les deux métriques de la famille λ_2), mais les candidats suivants sont dispersés sur des couches et des métriques sans lien, et tous se tiennent dans un mouchoir entre 0,736 et 0,779. Là où Llama-3.2-3B et Qwen3-1.7B montraient un décrochage net, on a ici un plateau qui frôle le seuil de bruit.

Ce résultat doit être rapporté comme faible. Il est du bon côté du seuil, mais c'est le seul de la série dont on ne parierait pas qu'il survive au split `test`.

Famille λ_2 : sixième confirmation sur sept. Le meilleur triplet repose de nouveau sur `connectivity_ratio`. Seul SmolLM3-3B (`spectral_radius`) fait exception. C'est la régularité la plus robuste de la série, et la seule à ne pas encore avoir souffert de contre-exemple franc.

Piste exploratoire : le nombre de têtes. gemma-2-2b-it possède 8 têtes, le minimum de la série, et obtient la marge la plus faible. En classant les sept modèles par nombre de têtes :

modèle	têtes	AUROC	marge sur le bruit
gemma-2-2b-it	8	0,7794	0,041
Qwen2.5-1.5B	12	0,8131	0,060
SmolLM3-3B	16	0,7913	0,038
Qwen3-1.7B	16	0,9069	0,157
Llama-3.2-3B	24	0,9169	0,160
Llama-3.2-1B	32	0,8838	0,133
SmolLM2-1.7B	32	0,8575	0,099

La corrélation entre nombre de têtes et marge vaut $r = +0,549$ (+0,600 avec l'AUROC brute). L'idée serait intuitive : plus un modèle a de têtes, plus il peut en spécialiser une.

Mais ce n'est pas établi. Avec $n = 7$, il faudrait $|r| > 0,75$ pour atteindre $p < 0,05$. Surtout, les deux modèles à 16 têtes affichent les marges les plus écartées de tout le tableau (0,038 et 0,157), ce qui montre que le nombre de têtes est au mieux un facteur parmi d'autres. À mentionner comme observation descriptive, pas comme résultat — deux régularités apparentes de cette série sont déjà tombées au modèle suivant.

Tendance en profondeur. $r = -0,610$, décroissance nette (5,44 sur les cinq premières couches contre 3,15 sur les cinq dernières). Six modèles sur sept décroissent, seul SmolLM2-1.7B fait exception (+0,464). L'argument de contiguïté reste majoritaire sans être universel.

Mécanisme : inchangé. ARI moyen $-0,0035$, soit le hasard, pour la septième fois. Accord brut 0,580 contre une ligne de base triviale de 0,959. Corrélation séparation / détection : $-0,029$, toujours sans régularité sur la série.

À faire. Hypothèse pré-enregistrée : `layer=9`, `head=0`, `metric=connectivity_ratio`. Compte tenu de la marge de 0,041, ce modèle est le moins prometteur des sept ; il a en revanche valeur de test du protocole, puisqu'un résultat faible sur `train` devrait s'effondrer sur `test` si la correction pour sélection fait bien son travail.

4.8 Qwen2.5-3B-Instruct

Ce run change la conclusion de la série. Jusqu'ici, les sept runs concluaient tous à l'échec de « la voie agrégée ». Ce huitième modèle montre que cette formulation était trop large : c'est `cut_conductance` qui échoue, pas toute mesure agrégée.

Sur Qwen2.5-3B, trois des quatre scores agrégés culminent à la *même* couche L9 :

score	maximum	couche
<code>auroc_fiedler_value</code>	0,7981	L9
<code>auroc_cut_conductance</code>	0,6969	L9
<code>auroc_cut_modularity</code>	0,6425	L9
<code>auroc_spectral_entropy_norm</code>	0,6944	L35

Corrigé pour les $36 \times 4 = 144$ candidats agrégés (donc y compris le choix du score), le bruit donne un maximum de 0,670 en moyenne et 0,715 au 95^e centile. La valeur de 0,7981 n'est jamais atteinte en 400 tirages : $p < 0,003$. Même `cut_conductance` atteint ici $p = 0,04$.

C'est le premier signal agrégé de la série qui survive à la correction pour sélection. La concordance de trois scores sur la même couche renforce l'interprétation : il se passe quelque chose à L9, et ce n'est pas un artefact de maximum.

Révision : fiedler_value fonctionne sur trois modèles. Ce constat m'a conduit à reprendre les sept runs précédents avec la même correction. Le tableau complet :

modèle	couches	cut_cond.	p	fiedler	p
Llama-3.2-1B	16	0,6431	0,18	0,6038	0,985
Llama-3.2-3B	28	0,6362	0,42	0,6756	0,318
Qwen2.5-1.5B	28	0,6125	0,71	0,7569	0,003
Qwen2.5-3B	36	0,6969	0,04	0,7981	0,000
Qwen3-1.7B	28	0,6294	0,50	0,6569	0,613
SmolLM2-1.7B	24	0,6525	0,18	0,6244	0,917
SmolLM3-3B	36	0,6556	0,26	0,7594	0,000
gemma-2-2b-it	26	0,6406	0,34	0,6106	1,000

Trois modèles sur huit présentent un signal agrégé significatif, tous via `fiedler_value`, jamais via `cut_conductance` (sauf marginalement ici). L'énoncé « la voie agrégée échoue » doit donc être remplacé par : *cut_conductance échoue sur les huit modèles ; λ_2 du graphe agrégé réussit sur trois.*

Cette révision annule en particulier une affirmation de l'interprétation de Qwen2.5-1.5B, où j'écrivais que son `auroc_fiedler_value` de 0,7569 « n'est pas significatif pris isolément ». Corrigé pour 112 candidats, il l'est ($p = 0,003$). Un addendum daté a été ajouté au fichier concerné.

Ce que cela réorganise. Les résultats par tête désignaient déjà la famille λ_2 dans six modèles sur sept. La révision ci-dessus pointe la même quantité au niveau agrégé. Les deux voies convergent :

La connectivité algébrique λ_2 est le descripteur pertinent — mesurée par tête quand c'est possible, sur le graphe agrégé sinon. `cut_conductance`, autour duquel le projet a été construit comme « détecteur sans label », est la mauvaise statistique.

C'est cohérent avec le mécanisme déjà identifié : `cut_conductance` évalue la qualité d'une coupe *découverte* par le signe du vecteur de Fiedler, laquelle coupe est structurellement incapable d'isoler une minorité de 4%. λ_2 ne dépend pas de cette coupe : c'est une propriété du spectre, insensible au déséquilibre des groupes.

Par tête : huitième succès, structure riche.

couche, tête	métrique	AUROC
L18, tête 10	<code>fiedler_value</code>	0,8756
L18, tête 10	<code>connectivity_ratio</code>	0,8688
L23, tête 14	<code>fiedler_value</code>	0,8638
L23, tête 14	<code>connectivity_ratio</code>	0,8606
L25, tête 14	<code>connectivity_ratio</code>	0,8469
L3, tête 8	<code>connectivity_ratio</code>	0,8462

Sur 2880 candidats, bruit à 0,722 en moyenne et 0,753 au 95^e centile ; $p < 0,004$. Trois têtes distinctes dépassent 0,846, chacune confirmée par les deux métriques λ_2 , et la tête 14 apparaît à deux profondeurs (L23 et L25). C'est la structure la plus riche de la série. Les six meilleurs triplets sont tous de la famille λ_2 .

Mécanisme et tendances : inchangés. ARI moyen $-0,0049$, soit le hasard, pour la huitième fois. Accord brut 0,577 contre une ligne de base triviale de 0,962. Séparation décroissante avec la profondeur ($r = -0,292$; sept modèles sur huit décroissent). Corrélation séparation / détection $+0,025$, toujours sans régularité.

À faire. Deux hypothèses pré-enregistrables pour ce modèle, à rapporter sur `test` :

- par tête : `layer=18, head=10, metric=fiedler_value` (0,876) ;
- agrégé : `auroc_fiedler_value` à `layer=9` (0,798).

La seconde est la plus intéressante scientifiquement : un détecteur agrégé n'a besoin ni d'identifier une tête, ni de stocker un tenseur de features. Si elle tient sur `test`, c'est un résultat nettement plus simple à défendre et à déployer que la voie par tête.